

发布异常调查 Agent

面向产品经理、产品负责人
与发布负责人

场景

版本上线后，核心业务指标出现异常


我的工作

产品定义 · Agent 产品设计
评测体系 · 迭代决策

作品集 v1.0 · 非生产数据

帮助团队判断： 究竟是不是这次发布导致的？

系统维护竞争假设，通过受控工具取证与证据约束形成诊断；证据不足时给出有界结论，外部动作始终需要人工审批。



调查闭环

风险信号
调查
证据
诊断
审批
验证

发布后的第一判断，常常缺少完整证据

指标变化与发布时间接近，只能说明相关；可靠归因需要跨信息源验证。



01 信息分散

调查者需要在发布记录、指标分群、用户反馈和历史事故之间反复切换。

02 相关被误判为因果

版本与异常同时发生时，团队容易忽略流量结构、外部依赖或测量问题。

03 解释缺少证据约束

普通 LLM 可以快速生成合理叙述，却不保证每个判断都来自当前事故证据。

产品机会：把一次开放式排查，转化为有状态、有证据、有停止边界的调查流程。

从风险信号到恢复验证

每一步都向下一步提供结构化状态，模型只负责调查决策，运行时负责权限与边界。



用户获得的不只是答案，而是一条可回看、可审批、可验证的调查记录。

一次真实调查，在产品里是怎么发生的？

真实 Demo 将调查进度、竞争假设、证据状态和人工审批放在同一条可追溯流程中。



1 创建竞争假设

2 调用受控工具取证

3 证据保留来源与关系

4 继续调查或有界停止

5 诊断后进入审批与验证

来源：ReleaseGuard AI 当前公开 Demo 的真实界面截图；演示使用确定性回放数据。

竞争假设与区分性调查

Agent 优先寻找能区分多个解释的证据，而不是持续为第一个猜测寻找支持。

观察

核心指标
发布后下降

时间相关
尚未证明因果

A

版本 Bug

新版本用户异常更明显

B

流量结构变化

分群内稳定，流量权重改变

C

埋点测量问题

业务结果稳定，埋点指标下降

下一条最有区分力的证据

1

版本隔离

同平台比较新旧应用版本

区分版本特异异常与整体流量问题

2

分群稳定性

比较用户类型和地区内指标

识别分群汇总偏差与流量结构变化

3

互补业务结果

比较行为完成与埋点指标

区分真实故障与测量偏差

产品价值：减少确认偏误，让“为什么继续查这条证据”对用户和评测者都可解释。

工具结果 ≠ 证据 ≠ 诊断

ReleaseGuard 把机器返回、证据解释和最终结论分开保存，避免模型叙述覆盖事实。



Evidence Packet v2 保留事实范围与工具结果关联，综合结论模块不能补造缺失证据。

证据不足时，系统不强行给出根因

就绪判断将“是否继续调查”和“应该交付哪类结果”变成明确的产品状态。

继续取证

仍有竞争假设

存在调查预算
继续寻找区分证据

有据诊断

证据足够区分

主要假设已区分
且结论有证据约束

有界假设

已有领先方向

但现有证据仍然
不能唯一归因

可行动拒答

关键问题未解

预算或工具无法
解决关键不确定性

**“不知道”是合法
结果**

系统应告诉用户：已经确认什么、还缺什么、下一项最有价值的数据是什么。

运行时保证

工具预算 · 最大迭代次数
重复调用拦截 · 部分证据保留

审批是一条服务端安全边界

模型不能直接执行外部写操作；审批绑定具体诊断、具体动作和冻结参数。



公开演示中的审批仅改变演示状态，不会调用真实 GitHub 或线上系统。

用失败案例验证 Agent，而不是只展示成功演示

固定标准答案、保留完整运行轨迹，再分别评估取证、引用、证据约束与最终判断。

固定开发集评测

22 个案例

单轮

至少一项关键证据

22 / 22

运行后与标准答案对照

完整关键证据集

14 / 22

证据收集

受控调查信息源

5 类

40 次只读工具调用

1

固定标准答案

→

2

Agent 运行

→

3

证据评分

→

4

盲评

→

5

失败分类

→

6

迭代

真实结果与边界

取证强于最终表达

证据收集链路已形成

证据引用仍需加强

边界失败被保留

部分运行触发能力边界

不通过重跑覆盖失败

综合结论仍有断层

证据到诊断的转化

证据约束仍需完善

最终 V8 使用 gpt-5.6-sol。合成、可复现的单轮开发集评测，用于验证调查与评测方法，不代表生产环境准确率。

来源：最终 V8 评测报告与盲评摘要 · 标准答案未进入 Agent 运行时

从低分追到可验证的产品机制

没有继续盲调提示词，而是先做失败分类，再用最小改动和受控探针验证假设。



这两个结果是局部受控探针，不代表整体评测准确率提升。

我负责把业务问题转译为 Agent 产品机制

工作范围覆盖产品定义、Agent 设计、评测体系和迭代决策，代码用于把这些产品约束变成可运行系统。

01

产品定义

- 1 目标用户与使用场景
- 2 发布风险调查边界
- 3 端到端产品流程

02

Agent 产品设计

- 1 竞争假设与证据
- 2 工具契约与就绪判断
- 3 人工审批

03

评测体系

- 1 标准答案与固定案例集
- 2 盲评机制
- 3 失败分类

04

迭代决策

- 1 定位失败阶段
- 2 设计受控探针
- 3 最小改动与主动冻结

作品集目标达到后停止针对评测调优，把剩余问题公开记录为能力边界。

明确能力边界，才能让 Agent 迭代真正可验证

作品集 v1.0 已完成功能冻结；后续只将未解决问题作为未来方向，不继续针对评测调参。

当前限制

- 1 合成、可复现的开发集；最终评测仅运行一轮，未做多随机种子或 3×22
- 2 规划器的查询选择仍受模型采样影响；盲评模型也存在方差
- 3 真实写操作仅支持 CREATE_GITHUB_ISSUE；没有自动修复或自主回滚
- 4 公开演示使用确定性回放，不代表真实企业部署或客户投资回报

未来方向

- 提升能力边界契约的稳定性
- 改善证据引用与结论投影
- 完成同模型多随机种子验证
- 在真实数据接入后重新评估

李超

UNSW 信息技术硕士 ·
人工智能方向
2027 届 · AI 产品经理

[在线演示](#) ↗

[GitHub](#) ↗