

AI PRODUCT MANAGER

李超

AI 产品经理 项目作品集

把 AI 从 Demo 变成
可评测、可约束、可落地的产品

UNSW Master of Information Technology
Artificial Intelligence 方向 · 2027 届校招

求职方向 AI 产品经理

我关注的不仅是模型能否回答，
而是产品能否稳定完成任务。

1 业务问题

定义值得解决的场景

2 Agent workflow

模型 + 工具 + 状态 + 约束

3 评测体系

指标 + Case Review

4 产品落地

Prototype · Demo · Deployment

核心能力

产品定义 · Agent 机制 · 数据评测 · 失败复盘 · Demo 落地

让上线异常从“人工排查”变成“Agent 调查”

核心不是让 AI 直接给答案，而是让它基于工具调用和证据逐步完成调查。

传统流程

信息碎片化，让调查依赖经验与跨团队协作

- 1

异常发现

多系统切换 · 人工提出假设
- 2

查指标

调查耗时长 · 直接总结易产生无依据结论
- 3

查发布
- 4

找团队
- 5

猜根因
- 6

决策

痛点：答案快，但无法说明“为什么可信”

流程重构

产品方案

证据驱动的受约束 Agent Loop



统计检测
→ 风险事件
→ Agent 调查
→ 审批与验证

可追踪：每一步有状态 · 可回溯：结论关联证据 · 可审计：外部动作需审批

真实界面截取自 ReleaseGuard 公开演示；数据为确定性 Demo / Replay，不代表生产流量。

Agent 不是一个 Prompt，而是一条可控的产品 workflows

模型负责规划，工具负责取证，运行时负责约束；证据不足时继续调查，而不是提前下结论。



运行支撑：Agent Loop · Tool Adapter · Approval · Verification · Benchmark · Harness · Scorer

用任务完成、诊断质量、可信度、效率与人机协同共同评估

评测目标不是“模型说得像不像”，而是 Agent 能否在约束内完成一次有据可查的调查。

Benchmark

22 Case

20 完成 · 2 失败

全链路完成率

90%+

End-to-End Completion

根因识别准确率

75–85%

Root Cause Accuracy

有据结论率

90%+

Evidence-grounded

无需人工纠偏

约 70%

No-intervention Rate

效率对比


约 30 分钟 → **约 5–8 分钟**

人工跨系统调查

Agent 调查

效率提升来自流程自动化与有界工具调用，不来自省略证据。

评测闭环



数据口径：项目 22-case 确定性 Benchmark 与提供的评测汇总；合成/可复现实验数据，不代表生产流量。

一次失败 Case，暴露的不是“模型笨”，而是执行约束不充分

当 region 分段返回 EMPTY，Planner 仍沿错误方向继续推理；修复重点因此落在 Harness 与语义校验机制。



INCONCLUSIVE ≠ 失败：证据不足时拒绝制造“看似合理”的根因，是可信 Agent 的产品能力。

LLM 负责理解隐性语义，规则负责稳定边界，人负责最终裁决

产品目标不是替代质检员，而是扩大覆盖、统一初判，并把争议 Case 送入可追溯的复核流程。

业务问题

传统人工抽检

- 01 **覆盖率低** 只能抽样
- 02 **标准不一** 判断依赖经验
- 03 **隐性违规** 关键词难捕捉
- 04 **复核成本** 上下文回看耗时

产品判断：高覆盖不等于高可信，必须保留人工复核与版本化结果。

产品 workflow



规则：关键词 / 正则 / SOP

覆盖：质检概览 · 会话管理 · 规则 / 方案 / 任务 · 结果复核 · 离线评测

重点 Case · 隐性推诿



不是只看 Accuracy，而是同时检查指标与错误 Case

客服违规识别中，漏掉真实违规（FN）往往比误报更危险，因此 Recall 与 FN Review 必须进入产品决策。



指标 + Case Review 的评测闭环

1 看指标

Precision / Recall / F1 识别整体偏差

2 拆错误

分别查看 FP 与 FN 的具体语义

3 改机制

调整规则、Prompt、阈值与复核策略

4 再评测

固定 Gold Label，避免只看单次 Demo

从 AI Demo 到可评测、可约束、可落地的 AI 产品

我能把业务问题转译为 AI 产品机制，并用指标、失败 Case 与人机协同边界持续迭代。

01 AI 产品设计

Agent Workflow
RAG / LLM Application
Human-in-the-loop

02 产品能力

需求分析 · 用户场景
PRD / Workflow
产品指标

03 AI 工程理解

Prompt · Tool Calling
Structured Output · JSON Schema
Benchmark · Harness

04 评测与迭代

Gold Label
Precision / Recall / F1
Failure Case Analysis

05 项目落地

Prototype · Demo
Deployment · GitHub
可运行作品

李超

UNSW MIT
Artificial Intelligence
2027 届 · AI 产品经理

PORTFOLIO

项目链接

[ReleaseGuard AI · 在线 Demo ↗](#)

[ReleaseGuard AI · GitHub ↗](#)

公开 Demo 使用确定性 Replay 数据，不触发真实外部写操作。